

Estado del Arte de Estrategias para Reducir el Sim2Real Gap en Gemelos Digitales: Técnicas, Validación y Aplicaciones Prácticas(2023-2025)

Lucia Pereda

Trabajo de Investigación de Final de Carrera

Universidad Abierta Interamericana

lucia.pered@alumnos.uai.edu.ar

28 de noviembre de 2025

Índice

1. Planteamiento del Problema	5
1.1. Contexto General	5
1.2. Naturaleza del Problema	5
1.2.1. Diferencias de Modelado Físico	5
1.2.2. Discrepancias Sensoriales	5
1.2.3. Diferencias de Comportamiento de Agentes	6
1.3. Impacto del Problema	6
1.3.1. Degradación de Desempeño	6
1.3.2. Riesgos de Seguridad	6
1.3.3. Costes de Desarrollo	7
1.4. Desafíos Específicos	7
1.4.1. Fidelidad de Simuladores	7
1.4.2. Escasez de Datos Reales	7
1.4.3. Transferibilidad de Políticas	8
1.5. Relevancia e Importancia	8
2. Objetivos	8
2.1. Objetivo General	8
2.2. Objetivos Específicos	9
2.2.1. Analizar Técnicas de Domain Randomization	9
2.2.2. Revisar Métodos de Domain Adaptation	9
2.2.3. Evaluar Enfoques de Transfer Learning	10
2.2.4. Identificar Prácticas de Calibración y Validación	10
3. Alcance	11
3.1. Delimitación Temporal	11
3.2. Delimitación Tecnológica	11
3.2.1. Tecnologías Incluidas	11
3.2.2. Tecnologías Excluidas	12
3.3. Delimitación de Dominios de Aplicación	12
3.3.1. Conducción Autónoma	12
3.3.2. Manipulación Robótica	13
3.3.3. Manufactura Inteligente y Sistemas Industriales	13
3.4. Delimitación Metodológica	13
3.4.1. Criterios de Inclusión de Literatura	13
3.4.2. Criterios de Exclusión	14
3.5. Limitaciones Reconocidas	14

3.5.1. Limitaciones de Cobertura	14
3.5.2. Limitaciones Metodológicas	14
3.6. Productos Esperados	14
4. Estado del Arte	15
4.1. Introducción al Estado del Arte	15
4.2. Domain Randomization: Robustez a través de la Variabilidad	15
4.2.1. Fundamentos y Principios	15
4.2.2. Trabajos Representativos	16
4.2.3. Parámetros Típicos de Aleatorización	17
4.2.4. Estrategias de Muestreo	18
4.2.5. Limitaciones y Desafíos	18
4.3. Domain Adaptation: Alineación de Distribuciones	19
4.3.1. Fundamentos Conceptuales	19
4.3.2. Traducción de Imagen con Cycle-Generative Adversarial Networks (Red generativa antagonica)	19
4.3.3. Aprendizaje Contrastivo para Diagnóstico de Fallos	20
4.3.4. Métodos de Alineación de Características	20
4.3.5. Ventajas y Limitaciones	21
4.4. Transfer Learning y Real-to-Sim-to-Real	21
4.4.1. Transfer Learning Clásico: Sim-to-Real	21
4.4.2. Real-to-Sim-to-Real: Un Paradigma Emergente	21
4.4.3. Curriculum Learning para Transferencia Progresiva	22
4.4.4. Meta-Learning para Adaptación Rápida	23
4.5. Calibración, Validación y Gemelos Digitales Ejecutables	23
4.5.1. El Concepto de Executable Digital Twins (xDT)	23
4.5.2. Control predictivo no lineal (NMPC) Adaptativo con Gemelos Digitales Paralelos	23
4.5.3. Benchmarking de la brecha de simulació-realidad	24
4.5.4. Identificación de sistemas para Calibración	25
4.6. Enfoques Híbridos y Emergentes	26
4.6.1. Combinación de Múltiples Estrategias	26
4.6.2. Mixed-Reality Digital Twins	26
4.6.3. Simuladores Diferenciables	27
4.7. Análisis por Dominio de Aplicación	27
4.7.1. Conducción Autónoma	27
4.7.2. Manipulacion Robótica	28
4.7.3. Manufactura Inteligente	28
4.8. Síntesis y Tendencias Emergentes	29

4.8.1.	Convergencia hacia Soluciones Híbridas	29
4.8.2.	Importancia de la Validación Cuantitativa	29
4.8.3.	Hacia Gemelos Digitales Adaptativos	30
4.8.4.	Integración de Conocimiento Experto	30
4.8.5.	Áreas de Oportunidad Identificadas	30
4.8.6.	5. Conclusión	31
4.9.	6. Trabajos Futuros	31
4.9.1.	6.1. Gemelos Digitales Adaptativos con Aprendizaje Continuo	31
4.9.2.	9.2. Estandarización de Métricas y Benchmarks	33
4.9.3.	9.3. Simuladores Diferenciables para Optimización End-to-End	35
4.9.4.	9.4. Integración de Modelos Fundacionales	38
4.9.5.	9.5. Validación Formal y Certificación	39
4.9.6.	9.6. Escalabilidad a Sistemas Multi-Agente	41
4.9.7.	9.7. Explicabilidad e Interpretabilidad	43
4.9.8.	9.8. Aplicaciones Emergentes	44
4.9.9.	9.9. Democratización mediante Herramientas y Ecosistemas .	46
4.9.10.	9.10. Consideraciones Éticas y Sociales	48
4.9.11.	9.11. Síntesis de Trabajos Futuros	49

1. Planteamiento del Problema

1.1. Contexto General

El desarrollo de sistemas autónomos y ciberfísicos ha experimentado un crecimiento exponencial en los últimos años, impulsado por avances en inteligencia artificial, aprendizaje por refuerzo y simulación computacional. En este contexto, los **gemelos digitales** (digital twins) han emergido como una herramienta fundamental para el diseño, entrenamiento y validación de sistemas complejos antes de su despliegue en entornos reales [16, 43] así como también una herramienta fundamental para la toma de decisiones estratégicas en la industria manufacturera.

Un gemelo digital se define como una representación virtual de un sistema físico que permite simular, predecir y optimizar su comportamiento en condiciones controladas. Sin embargo, uno de los desafíos más críticos en la aplicación de gemelos digitales es el denominado **sim2real gap** o “brecha de simulación-realidad”. Este fenómeno se refiere a la divergencia entre el comportamiento de un sistema en un entorno simulado y su desempeño en el mundo real [2, 16] la cual trae consigo una discrepancia de resultados que afecta el desempeño y por consecuencia la confianza en los gemelos digitales .

1.2. Naturaleza del Problema

La brecha simulación-realidad (Sim2Real) surge fundamentalmente de las diferencias estructurales entre los entornos virtuales y físicos, que pueden clasificarse en varias categorías:

1.2.1. Diferencias de Modelado Físico

Las simulaciones requieren simplificaciones y aproximaciones de las leyes físicas reales. Aspectos como la fricción, la elasticidad de materiales, la dinámica de fluidos y las interacciones complejas entre objetos no pueden replicarse con fidelidad perfecta en entornos virtuales [2, 30]. En el caso de vehículos autónomos, por ejemplo, la dinámica de neumáticos, la suspensión y las interacciones con diferentes superficies presentan desafíos significativos de modelado [43].

1.2.2. Discrepancias Sensoriales

Los sensores virtuales generan datos que difieren sistemáticamente de sus contrapartes reales debido a:

- **Diferencias de iluminación:** Las condiciones de luz en simulación raramente

capturan la complejidad de la iluminación natural, sombras, reflejos y cambios atmosféricos [16, 19].

- **Texturas y materiales:** Las propiedades visuales de superficies y objetos en simulación presentan artefactos y simplificaciones que no existen en la realidad [22].
- **Ruido sensorial:** Los sensores reales presentan patrones de ruido, distorsiones y fallos que son difíciles de modelar con precisión.

1.2.3. Diferencias de Comportamiento de Agentes

En escenarios multi-agente (tráfico vehicular, interacciones humano-robot, sistemas colaborativos), el comportamiento de otros agentes en simulación suele basarse en modelos simplificados que no capturan la variabilidad y complejidad del comportamiento humano real [43, 44].

1.3. Impacto del Problema

Las consecuencias de la brecha simulacion-realidad son significativas y multidimensionales:

1.3.1. Degradación de Desempeño

Los modelos de aprendizaje automático, controladores y algoritmos de percepción entrenados en simulación experimentan una caída dramática en su rendimiento cuando se despliegan en entornos reales. Esta degradación puede manifestarse como:

- Reducción en la precisión de detección de objetos [22]
- Inestabilidad en controladores de movimiento [31]
- Fallos en la toma de decisiones en situaciones críticas [11, 43]

1.3.2. Riesgos de Seguridad

En aplicaciones críticas como conducción autónoma, robótica médica o sistemas industriales, el sim2real gap puede comprometer la seguridad de personas y equipos. La incapacidad de un sistema para responder adecuadamente a situaciones reales no previstas en simulación puede resultar en accidentes o fallos catastróficos [16, 20, 43].

1.3.3. Costes de Desarrollo

La brecha simulación-realidad obliga a ciclos adicionales de:

- **Reentrenamiento:** Necesidad de recolectar datos reales y reentrenar modelos [5, 17]
- **Ajuste manual:** Calibración intensiva de parámetros en entornos reales [2]
- **Pruebas extensivas:** Validación prolongada en condiciones reales antes del despliegue [27, 35]

Estos ciclos adicionales incrementan significativamente los tiempos de desarrollo y los costes asociados, reduciendo la viabilidad económica de soluciones basadas en simulación [45].

1.4. Desafíos Específicos

La literatura reciente identifica varios desafíos específicos que complican la reducción de la brecha de simulación-realidad:

1.4.1. Fidelidad de Simuladores

Lograr simuladores de alta fidelidad que repliquen con precisión la física, los sensores y las dinámicas del mundo real requiere:

- Modelos computacionales complejos que demandan recursos significativos [2, 19]
- Calibración exhaustiva basada en datos reales [26, 34]
- Validación continua para mantener la correspondencia con sistemas físicos en evolución [14]

1.4.2. Escasez de Datos Reales

Aunque la simulación permite generar grandes volúmenes de datos sintéticos, la obtención de datos reales etiquetados para validación y refinamiento sigue siendo costosa y limitada, especialmente en:

- Situaciones de borde o casos extremos [3, 42]
- Condiciones ambientales específicas [40]
- Escenarios de fallo o emergencia [32]

1.4.3. Transferibilidad de Políticas

Las políticas de control y toma de decisiones aprendidas en simulación pueden ser frágiles ante perturbaciones no modeladas en el entorno real, requiriendo mecanismos de adaptación y robustez [1, 28, 30].

1.5. Relevancia e Importancia

La reducción de esta brecha es crucial para:

1. **Acelerar el desarrollo de sistemas autónomos:** Permitiendo que el entrenamiento y validación inicial se realice en simulación de forma segura y económica [18, 43].
2. **Mejorar la seguridad:** Garantizando que los sistemas desplegados mantengan niveles de desempeño aceptables en condiciones reales [16, 20].
3. **Reducir costes:** Minimizando la necesidad de pruebas extensivas en hardware real y facilitando la iteración rápida de diseños [8, 45].
4. **Habilitar aplicaciones emergentes:** Como robótica colaborativa, manufactura ágil, vehículos autónomos y sistemas de asistencia médica [19, 21, 39].

En resumen, el sim2real gap representa una barrera fundamental entre el potencial de los gemelos digitales y su aplicación práctica efectiva. Abordar este desafío requiere un enfoque multidisciplinario que combine técnicas de aprendizaje automático, modelado físico, ingeniería de sistemas y validación experimental.

2. Objetivos

2.1. Objetivo General

Caracterizar, clasificar y evaluar las estrategias recientes (2023-2025) para reducir el sim2real gap en gemelos digitales, analizando su aplicabilidad, eficacia y limitaciones en dominios representativos como conducción autónoma, robótica y manufactura 4.0.

Este objetivo busca proporcionar una visión comprehensiva del estado actual de las técnicas disponibles para cerrar la brecha simulación-realidad, identificando tendencias emergentes, mejores prácticas y áreas de oportunidad para investigación futura.

2.2. Objetivos Específicos

2.2.1. Analizar Técnicas de Domain Randomization

Objetivo: Revisar y evaluar las técnicas de aleatorización de dominio (domain randomization) aplicadas en gemelos digitales, examinando su efecto sobre la robustez de políticas de control y sistemas de percepción.

Justificación: Domain randomization ha emergido como una de las estrategias más prometedoras para mejorar la generalización de modelos entrenados en simulación. Al exponer los sistemas a una amplia variedad de condiciones simuladas, se busca que desarrollen robustez ante las variaciones inherentes del mundo real [19, 30, 43].

Alcance específico:

- Identificar parámetros clave sujetos a aleatorización (físicos, visuales, sensoriales)
- Evaluar estrategias de muestreo y distribuciones de aleatorización
- Analizar casos de estudio en aprendizaje por refuerzo y visión por computadora
- Examinar métricas de evaluación de robustez y transferibilidad

2.2.2. Revisar Métodos de Domain Adaptation

Objetivo: Examinar los métodos de adaptación de dominio y técnicas de traducción imagen-a-imagen (image-to-image translation) que permiten cerrar brechas visuales y de representación entre simulación y realidad.

Justificación: Las discrepancias visuales constituyen una fuente importante del sim2real gap, especialmente en sistemas basados en visión. Técnicas como CycleGAN, redes adversariales generativas y métodos de aprendizaje contrastivo ofrecen mecanismos para alinear las distribuciones de datos simulados y reales [7, 22].

Alcance específico:

- Revisar arquitecturas de traducción de dominio (GAN, CycleGAN, StyleGAN)
- Analizar métodos de alineación de características y aprendizaje contrastivo
- Evaluar estrategias de adaptación no supervisada y semi-supervisada
- Examinar aplicaciones en percepción visual y detección de objetos

2.2.3. Evaluar Enfoques de Transfer Learning

Objetivo: Analizar estrategias de transfer learning, incluyendo pipelines de real-to-sim-to-real, que combinan pre-entrenamiento en simulación con refinamiento mediante datos reales.

Justificación: El transfer learning permite aprovechar el conocimiento adquirido en simulación mientras se ajusta a las particularidades del entorno real con cantidades limitadas de datos. Los enfoques bidireccionales (real-to-sim-to-real) representan una evolución prometedora que utiliza datos reales para mejorar la simulación antes de la transferencia final [23, 44].

Alcance específico:

- Analizar arquitecturas y estrategias de pre-entrenamiento en simulación
- Evaluar técnicas de fine-tuning con datos reales limitados
- Examinar curriculum learning y entrenamiento progresivo
- Revisar pipelines real-to-sim-to-real y sus beneficios

2.2.4. Identificar Prácticas de Calibración y Validación

Objetivo: Identificar y evaluar prácticas de calibración, validación y benchmarking que garanticen la fidelidad de gemelos digitales y certifiquen la transferencia efectiva a aplicaciones industriales.

Justificación: La calibración sistemática y la validación rigurosa son fundamentales para cuantificar y reducir el sim2real gap. El concepto de gemelos digitales ejecutables (executable Digital Twins - xDT) y técnicas de identificación de sistemas proporcionan marcos metodológicos para lograr correspondencia verificable entre simulación y realidad [2, 19, 37].

Alcance específico:

- Revisar metodologías de identificación de parámetros y system identification
- Analizar marcos de gemelos digitales ejecutables (xDT)
- Evaluar métricas de fidelidad y benchmarks de sim2real gap
- Examinar procesos de validación y certificación en contextos industriales

3. Alcance

3.1. Delimitación Temporal

Este trabajo de investigación se enfoca en **literatura académica publicada entre 2023 y 2025**, con el objetivo de capturar las técnicas más recientes, tendencias emergentes y validaciones experimentales actuales en el campo de la reducción del sim2real gap en gemelos digitales. Elegí este marco temporal ya que es cuando se produjo el auge de la inteligencia artificial.

Justificación: El período 2023-2025 representa una fase de maduración significativa en este campo, caracterizada por:

- Mayor disponibilidad de simuladores de alta fidelidad
- Aplicaciones prácticas en entornos industriales reales
- Integración de técnicas de deep learning de última generación
- Desarrollo de frameworks de gemelos digitales ejecutables
- Mayor adopción de IA en la vida cotidiana de las personas

3.2. Delimitación Tecnológica

3.2.1. Tecnologías Incluidas

El estudio abarcará las siguientes tecnologías y enfoques metodológicos:

Simuladores y Plataformas de Gemelos Digitales:

- Simuladores de física de alta fidelidad (MuJoCo, PyBullet, Isaac Sim)
- Motores de renderizado fotorrealista (Unreal Engine, Unity, Blender)
- Plataformas de gemelos digitales ejecutables (xDT frameworks)
- Entornos de simulación específicos de dominio (CARLA para conducción, Gazebo para robótica)

Técnicas de Aprendizaje Automático:

- Aprendizaje por refuerzo (Reinforcement Learning - RL)
- Aprendizaje profundo supervisado y no supervisado
- Redes adversariales generativas (GANs) y variantes

- Métodos de aprendizaje contrastivo
- Transfer learning y domain adaptation

Métodos de Calibración y Validación:

- Identificación de sistemas (system identification)
- Optimización basada en simulación
- Calibración de parámetros mediante optimización bayesiana
- Técnicas de validación cruzada simulación-realidad

3.2.2. Tecnologías Excluidas

Quedan fuera del alcance de este estudio:

- Desarrollo de hardware de sensores (salvo cuando se vincule directamente con estrategias de transferencia)
- Optimizaciones puramente computacionales no relacionadas con fidelidad de simulación
- Fabricación y diseño de actuadores físicos
- Aspectos de ciberseguridad en gemelos digitales (salvo impacto en transferencia)

3.3. Delimitación de Dominios de Aplicación

El estudio priorizará tres dominios de aplicación principales, seleccionados por su relevancia, madurez de investigación y disponibilidad de validaciones experimentales:

3.3.1. Conducción Autónoma

Justificación: La conducción autónoma representa uno de los casos de uso más desafiantes y estudiados del sim2real gap, involucrando percepción compleja, toma de decisiones en tiempo real y requisitos estrictos de seguridad [11, 43].

Aspectos específicos:

- Entrenamiento de políticas de conducción mediante RL
- Percepción visual y fusión sensorial (cámaras, LiDAR, radar)
- Modelado de dinámica vehicular
- Simulación de escenarios de tráfico y comportamiento de otros agentes

3.3.2. Manipulación Robótica

Justificación: La manipulación robótica presenta desafíos únicos relacionados con el contacto físico, deformación de objetos y control de precisión, siendo un área activa de investigación en sim2real [22–24].

Aspectos específicos:

- Aprendizaje de políticas de agarre (grasping)
- Manipulación de objetos deformables
- Ensamblaje y tareas de precisión
- Interacción humano-robot

3.3.3. Manufactura Inteligente y Sistemas Industriales

Justificación: La manufactura ágil y los sistemas de producción flexibles se benefician significativamente de gemelos digitales para optimización, diagnóstico de fallos y reconfiguración rápida [7, 19, 38].

Aspectos específicos:

- Optimización de líneas de producción
- Diagnóstico predictivo de fallos
- Calibración de procesos industriales
- Sistemas de ensamblaje colaborativos

3.4. Delimitación Metodológica

3.4.1. Criterios de Inclusión de Literatura

Se incluirán trabajos que cumplan al menos uno de los siguientes criterios:

1. **Validación experimental real:** Estudios que presenten resultados cuantitativos de transferencia de simulación a sistemas físicos reales
2. **Propuestas metodológicas novedosas:** Nuevas técnicas o frameworks para reducir el sim2real gap con fundamentación teórica sólida
3. **Estudios comparativos:** Análisis que comparan múltiples estrategias de reducción del gap
4. **Benchmarks y métricas:** Trabajos que propongan o utilicen métricas cuantitativas del sim2real gap

3.4.2. Criterios de Exclusión

Se excluirán:

- Trabajos previos a 2023 (excepto referencias fundamentales en contexto)
- Estudios puramente teóricos sin vinculación a aplicaciones prácticas
- Publicaciones sin revisión por pares (con excepciones para preprints de alta calidad en arXiv)
- Trabajos centrados exclusivamente en simulación sin abordar transferencia a realidad

3.5. Limitaciones Reconocidas

3.5.1. Limitaciones de Cobertura

- **Sesgo de publicación:** Estudios con resultados negativos o transferencias no exitosas pueden estar subrepresentados en la literatura
- **Acceso a datos:** Muchas aplicaciones industriales no publican resultados completos por razones de confidencialidad
- **Idioma:** Se priorizará literatura en inglés y español, potencialmente excluyendo contribuciones en otros idiomas

3.5.2. Limitaciones Metodológicas

- **Heterogeneidad de métricas:** La falta de métricas estandarizadas del sim2real gap dificulta comparaciones directas entre estudios
- **Variabilidad de plataformas:** Diferentes simuladores y configuraciones experimentales limitan la reproducibilidad y comparabilidad
- **Horizonte temporal:** El período 2023-2025 puede no capturar completamente técnicas emergentes aún en desarrollo

3.6. Productos Esperados

Este trabajo de investigación generará:

1. **Taxonomía de estrategias:** Clasificación estructurada de técnicas para reducir el sim2real gap

2. **Revisión crítica de literatura:** Análisis detallado de trabajos representativos en cada categoría
3. **Análisis comparativo:** Evaluación de fortalezas, limitaciones y aplicabilidad de diferentes enfoques
4. **Identificación de tendencias:** Reconocimiento de direcciones emergentes y áreas de oportunidad
5. **Recomendaciones prácticas:** Guías para selección de estrategias según contexto de aplicación

4. Estado del Arte

4.1. Introducción al Estado del Arte

La brecha simulacion-realidad ha sido reconocida como uno de los desafíos fundamentales en la aplicación práctica de gemelos digitales y sistemas entrenados en simulación. La literatura reciente (2023-2025) ha presenciado un crecimiento significativo en la diversidad y sofisticación de estrategias propuestas para mitigar esta brecha.

Las investigaciones contemporáneas revelan un consenso emergente: **no existe una solución única o universal para la brecha simulacion-realidad**. En cambio, las aproximaciones más exitosas combinan múltiples técnicas complementarias, adaptadas al dominio específico de aplicación y a las características particulares del sistema bajo estudio [16, 19, 43].

A continuación, se presenta una revisión estructurada de las principales categorías de estrategias identificadas en la literatura reciente, organizadas según su enfoque metodológico y propósito principal.

4.2. Domain Randomization: Robustez a través de la Variabilidad

4.2.1. Fundamentos y Principios

Domain randomization (aleatorización de dominio) se basa en un principio fundamental: **exponer el sistema durante el entrenamiento a una amplia variedad de condiciones simuladas para que desarrolle robustez ante las variaciones inevitables del mundo real** [30, 40, 43].

La hipótesis subyacente es que si un modelo puede funcionar correctamente en un conjunto suficientemente diverso de entornos simulados, será capaz de generalizar al

mundo real, que puede considerarse como una instancia particular dentro del espacio de variación explorado durante el entrenamiento [31].

4.2.2. Trabajos Representativos

Conducción Autónoma con Aprendizaje por Refuerzo En el paper de Voogd et al. (2023) presentan un enfoque comprehensivo para transferir políticas de conducción autónoma desde simulación a vehículos reales utilizando gemelos digitales [43]. Su trabajo implementa domain randomization en múltiples dimensiones:

- **Aleatorización física:** Variación de masa vehicular, coeficientes de fricción y parámetros de suspensión
- **Aleatorización visual:** Modificación de condiciones de iluminación, texturas de carretera y elementos del entorno
- **Aleatorización de sensores:** Introducción de diferentes patrones de ruido y distorsiones en cámaras y LiDAR

Los autores demuestran que las políticas entrenadas con domain randomization extensivo mantienen un desempeño aceptable en pruebas reales, con una reducción del 40 % en errores de seguimiento de trayectoria comparado con políticas entrenadas en simulación estática [43].

Manipulación robótica con Degradación de Actuadores En el paper de Park (2024) abordan un escenario realista pero frecuentemente ignorado: el desempeño de manipuladores robóticos con actuadores degradados [30]. Utilizan un gemelo digital del robot y aplican domain randomization sobre:

- **Parámetros de actuadores:** Torque máximo, velocidad de respuesta, zona muerta (deadband)
- **Propiedades de objetos:** Masa, coeficiente de fricción, centro de gravedad
- **Condiciones ambientales:** Temperatura, humedad (que afectan fricción y respuesta de motores)

Su enfoque basado en Proximal Policy Optimization (PPO) con domain randomization logra mantener precisión de posicionamiento dentro de $\pm 2\text{mm}$ incluso con degradación de actuadores del 30 %, mientras que políticas sin randomization fallan con degradaciones superiores al 15 % [30].

Benchmarking en Manufactura Ágil En el paper de Katyara (2024) presentan un benchmark sistemático del sim2real gap en contextos de manufactura ágil, evaluando específicamente el impacto de domain randomization en tareas de ensamblaje [19]. Su estudio es notable por proporcionar métricas cuantitativas del gap:

- **Fidelidad geométrica:** Discrepancia promedio de 3.2mm entre posiciones simuladas y reales
- **Fidelidad dinámica:** Error del 12 % en predicción de tiempos de tarea
- **Fidelidad de contacto:** 85 % de precisión en predicción de detección de colisiones

Los autores demuestran que domain randomization reduce el sim2real gap en un 35-45 % según la métrica considerada, siendo particularmente efectivo para mejorar la robustez ante variaciones geométricas [19].

4.2.3. Parámetros Típicos de Aleatorización

La literatura identifica tres categorías principales de parámetros sujetos a randomization:

Parámetros Físicos:

- Masas e inercias de objetos y robots
- Coeficientes de fricción (estática y dinámica)
- Rígidez y amortiguamiento de materiales
- Parámetros de actuadores (ganancia, retraso, saturación)
- Constantes gravitacionales (para aplicaciones aeroespaciales)

Parámetros Visuales:

- Iluminación (intensidad, dirección, color)
- Texturas de superficies y objetos
- Propiedades de materiales (reflectividad, rugosidad)
- Condiciones atmosféricas (niebla, lluvia)
- Posición y orientación de cámaras

Parámetros Sensoriales:

- Ruido de sensores (gaussiano, sal y pimienta)
- Distorsiones ópticas
- Latencia de sensores
- Resolución y frecuencia de muestreo
- Fallos intermitentes de sensores

4.2.4. Estrategias de Muestreo

La efectividad de domain randomization depende críticamente de cómo se muestrean los parámetros aleatorios. La literatura reciente explora varias estrategias:

- **Uniform Randomization:** Muestreo uniforme dentro de rangos predefinidos. Simple pero puede ser ineficiente, generando muchas configuraciones poco informativas [43].
- **Adaptive Domain Randomization (ADR):** Ajuste automático de rangos de randomization basado en el desempeño del agente. Los rangos se expanden gradualmente para aumentar la dificultad progresivamente [29].
- **Automatic Domain Randomization (AutoDR):** Uso de meta-aprendizaje para identificar distribuciones óptimas de parámetros que maximicen la transferibilidad [25].

4.2.5. Limitaciones y Desafíos

A pesar de su popularidad, domain randomization presenta limitaciones importantes:

1. **Costo computacional:** Entrenar con alta variabilidad requiere significativamente más muestras y tiempo de entrenamiento [19].
2. **Diseño de rangos:** Determinar rangos apropiados de aleatorización requiere conocimiento experto y puede requerir iteración [30].
3. **Reality gap residual:** Incluso con randomization extensivo, algunas discrepancias sistemáticas pueden persistir [43].
4. **Sobre-conservadurismo:** Randomization excesivo puede llevar a políticas demasiado conservadoras que sacrifican desempeño óptimo por robustez [27].

4.3. Domain Adaptation: Alineación de Distribuciones

4.3.1. Fundamentos Conceptuales

Domain adaptation aborda la brecha de simulación-realidad desde una perspectiva diferente: en lugar de buscar robustez mediante variabilidad, **busca alinear explícitamente las distribuciones de datos simulados y reales** [7, 22]. Este enfoque es particularmente relevante cuando las discrepancias son sistemáticas y predecibles.

4.3.2. Traducción de Imagen con Cycle-Generative Adversarial Networks (Red generativa antagonica)

Digital Twin (DT)-CycleGAN para Agarre Visual CycleGAN es una técnica que implica el entrenamiento automático de modelos de traducción de imagen a imagen sin ejemplos emparejados. Los modelos se entrena de forma no supervisada utilizando una colección de imágenes del dominio de origen y de destino que no necesitan estar relacionadas de ninguna manera. En el paper de Liu et al. (2023) proponen una arquitectura innovadora que combina gemelos digitales con CycleGAN para habilitar transferencia zero-shot de modelos de agarre visual [22]. El aprendizaje zero-shot (ZSL) es un escenario de machine learning en el que se entrena un modelo de IA para reconocer y categorizar objetos o conceptos sin haber visto previamente ningún ejemplo de esas categorías o conceptos. [IBM] Su enfoque es notable por varios aspectos:

Arquitectura:

- **Gemelo digital:** Replica precisa del robot y entorno de trabajo
- **CycleGAN bidireccional:** Traduce imágenes sim→real y real→sim
- **Red de agarre:** Predice posiciones y orientaciones de agarre

Proceso de entrenamiento:

1. Entrenar red de agarre en simulación con datos sintéticos abundantes
2. Entrenar CycleGAN con pares no emparejados de imágenes simuladas y reales
3. En inferencia real, traducir imágenes reales a dominio simulado antes de pasárlas a la red de agarre

Resultados:

- Tasa de éxito de agarre del 87 % en objetos no vistos (comparado con 45 % sin traducción)

- Transferencia zero-shot sin necesidad de datos reales etiquetados
- Reducción del 60 % en tiempo de desarrollo comparado con enfoques que requieren reentrenamiento [22]

4.3.3. Aprendizaje Contrastivo para Diagnóstico de Fallos

Sim2Real Knowledge Transfer con Contrastive Learning En el paper de Chen et al. (2024) abordan el desafío del diagnóstico de fallos asistido por gemelos digitales en entornos industriales desconocidos [7]. Su contribución principal es un framework de transferencia de conocimiento basado en aprendizaje contrastivo:

Metodología:

- **Representaciones invariantes:** Aprenden representaciones que capturan características esenciales de fallos independientemente del dominio
- **Contrastive loss:** Maximiza similitud entre representaciones de la misma clase de fallo en diferentes dominios
- **Adversarial alignment:** Minimiza la discrepancia de distribuciones entre simulación y realidad

Aplicación: Diagnóstico de fallos en rodamientos industriales:

- Dataset simulado: 50,000 ejemplos de 10 tipos de fallos
- Dataset real: 500 ejemplos reales (10 % del tamaño simulado)
- Precisión de diagnóstico: 92 % (comparado con 68 % sin domain adaptation)

Los autores demuestran que su enfoque es particularmente efectivo cuando los datos reales son escasos, una situación común en contextos industriales [7].

4.3.4. Métodos de Alineación de Características

Más allá de la traducción de imagen, la literatura reciente explora métodos que operan en espacios de características latentes:

- **Maximum Mean Discrepancy (MMD):** Minimiza la distancia entre distribuciones de características simuladas y reales en espacios de Hilbert [41].
- **Adversarial Domain Adaptation:** Utiliza discriminadores adversariales para hacer indistinguibles las características de ambos dominios [13].
- **Optimal Transport:** Formula la adaptación como un problema de transporte óptimo entre distribuciones [9].

4.3.5. Ventajas y Limitaciones

Ventajas:

- Efectivo para discrepancias visuales sistemáticas
- Puede funcionar con datos no emparejados (CycleGAN)
- Permite aprovechar grandes volúmenes de datos simulados

Limitaciones:

- Requiere datos reales (aunque no necesariamente etiquetados)
- Puede fallar ante discrepancias fundamentales de física o dinámica
- La traducción puede introducir artefactos que afecten el desempeño

4.4. Transfer Learning y Real-to-Sim-to-Real

4.4.1. Transfer Learning Clásico: Sim-to-Real

El paradigma tradicional de transfer learning en el contexto sim2real sigue un proceso secuencial:

1. **Pre-entrenamiento en simulación:** Entrenar modelos con grandes volúmenes de datos sintéticos
2. **Fine-tuning con datos reales:** Ajustar el modelo con cantidades limitadas de datos reales
3. **Despliegue:** Utilizar el modelo refinado en el sistema real

Este enfoque es ampliamente utilizado en conducción autónoma, donde Voogd et al. (2023) demuestran que políticas pre-entrenadas en simulación requieren solo 2-3 horas de datos reales para alcanzar desempeño comparable a políticas entrenadas completamente en datos reales (que requieren 50+ horas) [43].

4.4.2. Real-to-Sim-to-Real: Un Paradigma Emergente

RialTo: Reconciling Reality Through Simulation Lopez Torné et al. (2024) introducen un paradigma innovador que invierte el flujo tradicional: **usar datos reales para mejorar la simulación antes de la transferencia final** [23].

Pipeline RialTo:

1. **Fase Real-to-Sim:**

- Recolectar datos reales de interacciones (exitosas y fallidas)
- Utilizar estos datos para calibrar parámetros de simulación
- Identificar discrepancias sistemáticas entre comportamiento simulado y real

2. Fase Sim-to-Real:

- Entrenar políticas en la simulación calibrada
- Las políticas aprenden de errores reales reproducidos en simulación
- Desplegar políticas con mayor robustez ante condiciones reales

Resultados en manipulación robótica:

- Tasa de éxito en tareas de ensamblaje: 94 % (RialTo) vs. 76 % (sim-to-real directo)
- Reducción del 65 % en número de intentos reales necesarios para convergencia
- Mejor generalización a variaciones no vistas del entorno [23]

Ventajas del enfoque:

- La simulación se vuelve más fiel a la realidad mediante calibración basada en datos reales
- Errores reales informan el entrenamiento, mejorando robustez
- Reduce la necesidad de pruebas extensivas en hardware real

4.4.3. Curriculum Learning para Transferencia Progresiva

Zeng et al. (2023) proponen un enfoque de curriculum learning para transferencia gradual de simulación a realidad en tareas de agarre robótico [44]. Su método, denominado **Triple Regression**, estructura el entrenamiento en etapas de dificultad creciente:

Etapas del curriculum:

1. **Simulación idealizada:** Física perfecta, sensores sin ruido
2. **Simulación realista:** Introducción gradual de incertidumbres y variaciones
3. **Datos reales sintéticos:** Mezcla de datos simulados y reales aumentados
4. **Datos reales puros:** Fine-tuning final con datos reales exclusivamente

Resultados:

- Convergencia $3\times$ más rápida que entrenamiento directo
- Mejor estabilidad de entrenamiento (menor varianza)
- Tasa de éxito del 89 % en agarre de objetos diversos [44]

4.4.4. Meta-Learning para Adaptación Rápida

Aunque no específico del período 2023-2025, el meta-learning (aprender a aprender) ha ganado tracción como estrategia complementaria para transfer learning. La idea es entrenar modelos que puedan adaptarse rápidamente a nuevos dominios con pocas muestras [12].

Aplicaciones recientes incluyen:

- Adaptación rápida de controladores a nuevas dinámicas de robot
- Ajuste de modelos de percepción a nuevas condiciones de iluminación
- Personalización de políticas a preferencias de usuarios específicos

4.5. Calibración, Validación y Gemelos Digitales Ejecutables

4.5.1. El Concepto de Executable Digital Twins (xDT)

Los gemelos digitales ejecutables representan una evolución de los gemelos digitales tradicionales, enfatizando la **capacidad de ejecutar simulaciones de alta fidelidad que mantengan correspondencia verificable con el sistema físico** [2, 19].

Características distintivas de xDTs:

- **Bi-direccionalidad:** Flujo de información tanto de físico→digital como digital→físico
- **Sincronización temporal:** Capacidad de ejecutar en tiempo real o más rápido
- **Calibración continua:** Actualización automática de parámetros basada en observaciones reales
- **Validación cuantitativa:** Métricas explícitas de fidelidad y divergencia

4.5.2. Control predictivo no lineal (NMPC) Adaptativo con Gemelos Digitales Paralelos

Learning-Based NMPC Adaptation Allamaa et al. (2024) presentan un framework para control predictivo no lineal (NMPC) adaptativo en conducción autónoma, utilizando gemelos digitales paralelos [2].

Arquitectura:

- **Gemelo digital paralelo:** Ejecuta simulaciones en paralelo al sistema real en tiempo real
- **Módulo de identificación:** Compara predicciones con observaciones reales y ajusta parámetros
- **NMPC adaptativo:** Controlador que utiliza el modelo calibrado para optimización

Proceso de calibración:

1. Sistema real ejecuta maniobra bajo control NMPC con modelo nominal
2. Gemelo digital predice trayectoria esperada
3. Diferencias entre predicción y realidad alimentan algoritmo de identificación
4. Parámetros del modelo (masa, fricción, rigidez) se ajustan mediante optimización
5. NMPC se actualiza con modelo calibrado

Resultados en vehículo real:

- Reducción del 70 % en error de seguimiento de trayectoria después de calibración
- Convergencia de parámetros en ~5 minutos de conducción
- Adaptación automática a cambios (carga de pasajeros, presión de neumáticos) [2]

4.5.3. Benchmarking de la brecha de simulació-realidad

High-Fidelity Digital Twinning of Agile Manufacturing Katyara et al. (2024) desarrollan un benchmark comprehensivo para cuantificar el sim2real gap en manufactura ágil [19]. Su contribución principal es un conjunto de métricas multidimensionales:

Métricas de Fidelidad:

1. Fidelidad Geométrica (FG):

$$FG = 1 - \frac{\|p_{sim} - p_{real}\|}{\|p_{real}\|} \quad (1)$$

donde p representa posiciones de objetos/robots

2. Fidelidad Dinámica (FD):

$$FD = 1 - \frac{|t_{sim} - t_{real}|}{t_{real}} \quad (2)$$

donde t representa tiempos de ejecución de tareas

3. Fidelidad de Contacto (FC):

$$FC = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

precisión en detección de colisiones (verdaderos/falsos positivos/negativos)

4. Fidelidad Global (FG_{global}):

$$FG_{global} = w_1 \cdot FG + w_2 \cdot FD + w_3 \cdot FC \quad (4)$$

combinación ponderada de métricas individuales

Resultados en línea de ensamblaje real:

- Fidelidad geométrica: 96.8 % (error promedio 3.2mm)
- Fidelidad dinámica: 88 % (error temporal 12 %)
- Fidelidad de contacto: 85 %
- Fidelidad global: 90 % (con pesos $w_1=0.4$, $w_2=0.3$, $w_3=0.3$)

Los autores demuestran que domain randomization combinado con calibración iterativa mejora la fidelidad global de 75 % (baseline) a 90 % [19].

4.5.4. Identificación de sistemas para Calibración

La identificación de sistemas (system identification) es fundamental para calibrar gemelos digitales. Técnicas recientes incluyen:

- **Optimización Bayesiana:** Búsqueda eficiente en espacios de parámetros de alta dimensión [6]. Segun Wikipedia la optimización bayesiana es una estrategia de diseño secuencial para la optimización global de funciones de caja negra que no asume ninguna forma funcional. Suele emplearse para optimizar funciones caras de evaluar.
- **Gradientes Analíticos:** Uso de simuladores diferenciables para calcular gradientes exactos respecto a parámetros [10].
- **Aprendizaje por Refuerzo:** Formulación de la identificación como problema de RL donde el agente aprende a ajustar parámetros [4].

4.6. Enfoques Híbridos y Emergentes

4.6.1. Combinación de Múltiples Estrategias

La tendencia más clara en la literatura reciente es la **combinación sinérgica de múltiples técnicas** para abordar diferentes aspectos del sim2real gap simultáneamente.

Ejemplo: DT-CycleGAN + Domain Randomization Liu et al. (2023) no solo utilizan CycleGAN, sino que lo combinan con domain randomization durante el entrenamiento de la red de agarre [22]:

- **CycleGAN:** Cierra la brecha visual
- **Domain Randomization:** Proporciona robustez ante variaciones de iluminación y pose
- **Fine-tuning:** Ajuste final con pequeño conjunto de datos reales

Esta combinación logra mejor desempeño que cualquiera de las técnicas individualmente.

4.6.2. Mixed-Reality Digital Twins

Leveraging Physical and Virtual Worlds Samak et al. (2024) proponen un concepto innovador: **mixed-reality digital twins** que combinan elementos físicos y virtuales en un mismo entorno de entrenamiento [36].

Concepto:

- Robots físicos interactúan con objetos virtuales proyectados
- Sensores reales perciben entorno aumentado con elementos simulados
- Permite entrenar políticas multi-agente con algunos agentes físicos y otros virtuales

Ventajas:

- Reducción de costes (no requiere múltiples robots físicos)
- Seguridad (situaciones peligrosas se simulan)
- Escalabilidad (fácil agregar agentes virtuales)

Aplicación en vehículos autónomos:

- Entrenamiento de políticas de coordinación multi-vehículo

- Vehículo real interactúa con vehículos simulados en entorno aumentado
- Transferencia gradual: aumentar proporción de vehículos reales progresivamente [36]

4.6.3. Simuladores Diferenciables

Una tendencia emergente es el desarrollo de simuladores diferenciables que permiten calcular gradientes de métricas de desempeño respecto a parámetros de simulación [10, 15].

Ventajas:

- Calibración eficiente mediante descenso de gradiente
- Optimización end-to-end de políticas considerando dinámica
- Identificación de parámetros críticos para fidelidad

Limitaciones actuales:

- Alto costo computacional
- Dificultad para modelar contactos y fricción de forma diferenciable
- Limitaciones en realismo visual

4.7. Análisis por Dominio de Aplicación

4.7.1. Conducción Autónoma

La conducción autónoma ha sido uno de los dominios más activos en investigación de sim2real:

Desafíos específicos:

- Complejidad de interacciones multi-agente (tráfico)
- Requisitos estrictos de seguridad
- Alta dimensionalidad del espacio de estados
- Variabilidad de condiciones ambientales

Estrategias predominantes:

- Domain randomization para robustez ante condiciones meteorológicas y de iluminación [11, 43]
- Transfer learning con grandes datasets simulados (CARLA, LGSVL)

- Validación extensiva en circuitos cerrados antes de despliegue en vías públicas

Métricas de éxito:

- Reducción de intervenciones humanas
- Distancia entre desenganche (disengagement distance)
- Tasa de cumplimiento de reglas de tráfico

4.7.2. Manipulación Robótica

La manipulación robótica presenta desafíos únicos relacionados con contacto y deformación:

Desafíos específicos:

- Modelado preciso de contactos y fricción
- Deformación de objetos (especialmente blandos)
- Variabilidad de propiedades de objetos (peso, textura)
- Precisión requerida (sub-milimétrica en muchos casos)

Estrategias predominantes:

- CycleGAN y domain adaptation para percepción visual [22]
- Real-to-sim-to-real para calibración de física de contacto [23]
- Curriculum learning para transferencia progresiva [44]

Métricas de éxito:

- Tasa de éxito de agarre
- Precisión de posicionamiento
- Tiempo de ejecución de tarea

4.7.3. Manufactura Inteligente

La manufactura presenta oportunidades únicas para validación y calibración continua:

Desafíos específicos:

- Variabilidad de procesos y materiales
- Requisitos de alta disponibilidad (downtime costoso)

- Integración con sistemas legacy
- Necesidad de certificación y trazabilidad

Estrategias predominantes:

- Gemelos digitales ejecutables con calibración continua [2, 19]
- Aprendizaje contrastivo para diagnóstico de fallos [7]
- Benchmarking sistemático de fidelidad [19]

Métricas de éxito:

- Precisión de predicción de tiempos de ciclo
- Tasa de detección de fallos
- Reducción de rechazos de calidad

4.8. Síntesis y Tendencias Emergentes

4.8.1. Convergencia hacia Soluciones Híbridas

El análisis de la literatura revela una tendencia clara: **las soluciones más efectivas combinan múltiples estrategias** adaptadas al contexto específico [2, 19, 22, 23, 43]:

- **Domain randomization** proporciona robustez general
- **Domain adaptation** cierra brechas visuales específicas
- **Calibración continua** mantiene fidelidad a largo plazo
- **Transfer learning** aprovecha datos reales limitados

4.8.2. Importancia de la Validación Cuantitativa

Existe un reconocimiento creciente de la necesidad de métricas estandarizadas y benchmarks reproducibles para cuantificar la brecha [19, 27]:

- Propuestas de métricas multidimensionales
- Desarrollo de datasets de referencia
- Competiciones y desafíos académicos (sim2real challenges)

4.8.3. Hacia Gemelos Digitales Adaptativos

La visión emergente es de gemelos digitales que **se auto-calibran y adaptan continuamente** basándose en observaciones del sistema real [2, 39]:

- Identificación de parámetros en línea
- Detección automática de cambios en el sistema físico
- Actualización de modelos sin intervención humana

4.8.4. Integración de Conocimiento Experto

Se reconoce cada vez más el valor de incorporar conocimiento de dominio y modelos basados en primeros principios, en lugar de depender exclusivamente de aprendizaje de datos [33]:

- Modelos híbridos físicos-aprendidos
- Restricciones basadas en leyes físicas
- Arquitecturas de redes neuronales informadas por física (PINNs)

4.8.5. Áreas de Oportunidad Identificadas

La revisión de literatura identifica varias direcciones prometedoras para investigación futura:

1. **Transferencia multi-dominio:** Técnicas que funcionen en múltiples aplicaciones sin ajuste específico
2. **Certificación formal:** Métodos para garantizar formalmente propiedades de seguridad post-transferencia
3. **Eficiencia computacional:** Reducir el costo de simulación de alta fidelidad y domain randomization
4. **Explicabilidad:** Entender qué aspectos de las estrategias contribuyen más a cerrar el gap
5. **Generalización zero-shot:** Transferencia efectiva sin ningún dato real de ajuste

4.8.6. 5. Conclusión

El Sim2Real Gap representa uno de los desafíos más fundamentales en la intersección de simulación, aprendizaje automático y sistemas físicos. El análisis exhaustivo de la literatura 2023-2025 revela que el campo ha madurado significativamente, con técnicas que producen mejoras cuantificables y despliegues industriales con ROI demostrable.

Sin embargo, cerrar completamente el gap sigue siendo un problema abierto. La convergencia hacia enfoques híbridos, la evolución hacia gemelos adaptativos y el énfasis en validación rigurosa son señales alentadoras de progreso sostenido. La democratización de técnicas avanzadas mediante herramientas accesibles y la estandarización de métricas serán críticas para acelerar la adopción y el impacto.

El futuro del Sim2Real Gap no reside en encontrar una solución universal, sino en desarrollar frameworks principled que guíen la selección y combinación de técnicas según el contexto específico, y en construir gemelos digitales que co-evolucionen con sus contrapartes físicas, reduciendo el gap de manera continua y sostenible.

4.9. 6. Trabajos Futuros

El análisis del estado del arte y la identificación de brechas de conocimiento revelan múltiples direcciones prometedoras para investigación futura. Esta sección organiza las oportunidades según su potencial impacto, viabilidad y alineación con tendencias emergentes.

4.9.1. 6.1. Gemelos Digitales Adaptativos con Aprendizaje Continuo

Motivación y Contexto

Los gemelos digitales actuales son típicamente **estáticos**: una vez calibrados, sus parámetros permanecen fijos. Sin embargo, sistemas físicos reales cambian continuamente debido a desgaste, reconfiguración, degradación de sensores y cambios ambientales. Esta divergencia progresiva entre gemelo y realidad incrementa el Sim2Real Gap con el tiempo, requiriendo re-calibración manual costosa.

Visión: Desarrollar gemelos digitales que **co-evolucionen** con sus contrapartes físicas mediante actualización continua de parámetros basada en observaciones reales, manteniendo fidelidad sostenida sin intervención manual.

Direcciones de Investigación Específicas

9.1.1. Detección Automática de Drift **Objetivo:** Desarrollar algoritmos que detecten automáticamente cuándo las predicciones del gemelo divergen significativamente de observaciones reales, activando re-calibración.

Enfoques técnicos: - **Métodos estadísticos:** Pruebas de cambio de distribución (Kolmogorov-Smirnov, Maximum Mean Discrepancy) aplicadas a residuos de predicción vs observación. - **Aprendizaje auto-supervisado:** Entrenar detectores de anomalía que identifiquen cuándo observaciones reales caen fuera de la distribución de predicciones del gemelo. - **Métricas multi-dimensionales:** Combinar drift en múltiples variables (pose, velocidad, fuerzas) para detección robusta.

Métricas de éxito: - Detección de drift con $< 5\%$ falsos positivos y $< 10\%$ falsos negativos - Latencia de detección < 1 hora de operación divergente

Desafíos: - Distinguir drift real de variabilidad estocástica normal - Definir umbrales de drift que balanceen sensibilidad y especificidad

9.1.2. Actualización en Línea de Parámetros **Objetivo:** Desarrollar métodos de calibración en línea que actualicen parámetros del gemelo basándose en datos streaming del sistema físico, sin interrumpir operación.

Enfoques técnicos: - **System Identification incremental:** Algoritmos de mínimos cuadrados recursivos (RLS) que actualizan estimaciones de parámetros con cada nueva observación. - **Bayesian Optimization online:** Extensión de BO para optimización continua con función objetivo no estacionaria. - **Gradient-based optimization con simuladores diferenciables:** Calcular gradientes de error de predicción respecto a parámetros físicos y actualizar mediante descenso de gradiente.

Métricas de éxito: - Convergencia a parámetros correctos en < 100 observaciones - Overhead computacional $< 10\%$ del tiempo de simulación

Desafíos: - Estabilidad de actualización (evitar oscilaciones o divergencia) - Identificabilidad: algunos parámetros pueden ser no observables o confundidos

9.1.3. Aprendizaje Continuo de Dinámicas **Objetivo:** Integrar técnicas de aprendizaje continuo para que el gemelo aprenda correcciones de modelo a partir de discrepancias observadas, sin olvidar dinámicas previamente aprendidas.

Enfoques técnicos: - **Physics-Informed Neural Networks (PINNs) incrementales:** Entrenar redes neuronales que aprenden correcciones del modelo físico nominal, con pérdidas que incorporan ecuaciones diferenciales y datos observados. - **Meta-Learning para adaptación rápida:** Usar MAML o variantes para aprender inicializaciones que se adaptan rápidamente a nuevas configuraciones del sistema. - **Experience Replay y regularización:** Mantener buffer de observaciones pasadas y regularizar actualizaciones para evitar olvido catastrófico.

Métricas de éxito: - Reducción de error de predicción en 50% tras observar 500 nuevas muestras - Retención de desempeño en configuraciones antiguas ($< 10\%$ degradación)

Desafíos: - Balance entre plasticidad (aprender nuevo) y estabilidad (retener antiguo) - Escalabilidad a sistemas de alta dimensión (> 50 estados)

9.1.4. Gestión de Incertidumbre **Objetivo:** Cuantificar incertidumbre en predicciones del gemelo para decisiones conscientes de riesgo (cuándo confiar en gemelo vs sistema real).

Enfoques técnicos: - **Bayesian Deep Learning:** Usar redes neuronales bayesianas (dropout variacional, ensambles) para cuantificar incertidumbre epistémica. - **Propagación de incertidumbre:** Propagar incertidumbre de parámetros a través de simulaciones para obtener distribuciones de predicciones. - **Calibración de incertidumbre:** Asegurar que intervalos de confianza del gemelo estén bien calibrados (cobertura empírica nivel nominal).

Métricas de éxito: - Calibración de incertidumbre: error de calibración esperado (ECE) < 0.05 - Utilidad práctica: decisiones basadas en incertidumbre reducen fallos en 30 %

Impacto Esperado

Gemelos digitales adaptativos reducirían esfuerzo de re-calibración manual en 50-80 %, habilitando gemelos de largo plazo (años) sin intervención costosa. Aplicaciones críticas (conducción autónoma, robótica médica) se beneficiarían de fidelidad sostenida y decisiones conscientes de incertidumbre.

4.9.2. 9.2. Estandarización de Métricas y Benchmarks

Motivación y Contexto

La heterogeneidad de métricas y falta de benchmarks estandarizados dificulta comparación objetiva de técnicas y ralentiza el progreso del campo. Solo 3 benchmarks estandarizados fueron identificados en el análisis (Data-Link, AutoDRIVE, EAGERx), insuficientes para cubrir la diversidad de aplicaciones.

Visión: Establecer un ecosistema de benchmarks multi-dominio y métricas unificadas que permitan comparación rigurosa y reproducible de técnicas Sim2Real.

Direcciones de Investigación Específicas

9.2.1. Desarrollo de Benchmarks Multi-Dominio **Objetivo:** Crear benchmarks que cubran múltiples dominios (conducción, manipulación, manufactura) con protocolos estandarizados de evaluación.

Componentes requeridos: - **Datasets sintéticos y reales pareados:** Escenas idénticas capturadas en simulación y realidad con anotaciones consistentes. -

Métricas estandarizadas: Definición clara de métricas primarias (precisión, error, tasa de éxito) y secundarias (tiempo de inferencia, robustez). - **Protocolos de evaluación:** Splits train/val/test estandarizados, procedimientos de fine-tuning, confi-

guraciones de hardware. - **Leaderboards públicos:** Plataformas para submission de resultados y comparación transparente.

Benchmarks propuestos: - **Sim2Real-Drive:** Conducción autónoma (extensión de CARLA + datos reales pareados) - **Sim2Real-Grasp:** Manipulación robótica (extensión de Data-Link con más objetos y tareas) - **Sim2Real-Factory:** Manufactura inteligente (gemelos de líneas de producción + datos operativos reales)

Métricas de éxito: - Adopción por 20+ grupos de investigación en primeros 2 años - 50+ submissions a leaderboards - Publicación de 10+ papers comparando técnicas en benchmarks

9.2.2. Métricas Unificadas de Sim2Real Gap **Objetivo:** Definir métricas multi-dimensionales que capturen fidelidad perceptual, dinámica y comportamental, permitiendo comparación cross-domain.

Propuesta de métrica unificada:

$$\text{Sim2Real Gap Score} = w_p \cdot \Delta_{\text{perceptual}} + w_d \cdot \Delta_{\text{dynamic}} + w_b \cdot \Delta_{\text{behavioral}}$$

Donde: - $\Delta_{\text{perceptual}}$: Discrepancia en observaciones sensoriales (ej. distancia de distribuciones de imágenes, nubes de puntos) - Δ_{dynamic} : Discrepancia en trayectorias bajo mismas condiciones iniciales y comandos - $\Delta_{\text{behavioral}}$: Discrepancia en desempeño de tarea (ej. tasa de éxito, error de tracking) - w_p, w_d, w_b : Pesos específicos de aplicación (suma a 1)

Operacionalización: - $\Delta_{\text{perceptual}}$: Maximum Mean Discrepancy (MMD) entre features de imágenes sim y real - Δ_{dynamic} : Error RMS entre trayectorias simuladas y reales - $\Delta_{\text{behavioral}}$: Diferencia absoluta en métrica de tarea (ej. $|\text{éxito_sim} - \text{éxito_real}|$)

Validación: - Correlación con desempeño de transferencia ($r > 0.7$) - Sensibilidad a mejoras de técnicas (detecta diferencias de 5 pp en desempeño)

9.2.3. Competencias y Challenges **Objetivo:** Organizar competencias estilo DARPA Challenge enfocadas en transferencia sim-to-real con infraestructura común.

Propuesta de challenge: - **Sim2Real Robotics Challenge:** Competencia anual con tareas de manipulación y navegación - Fase 1 (simulación): Equipos entrenan políticas en simulador provisto - Fase 2 (transferencia): Políticas se evalúan en robots reales sin modificación (zero-shot) - Fase 3 (adaptación): Permitir fine-tuning con 100 demos reales - Premios: \$100k total, reconocimiento en conferencias principales

Infraestructura requerida: - Simulador estándar (ej. Isaac Sim, MuJoCo) -

Robots reales en múltiples ubicaciones (laboratorios participantes) - Plataforma de submission y evaluación automatizada

- Impacto esperado:** - Acelerar progreso mediante competencia y colaboración
- Establecer estado del arte claro y reproducible - Democratizar acceso a evaluación en robots reales

9.2.4. Estandarización en Organismos Internacionales **Objetivo:** Trabajar con organismos de estandarización (ISO, IEEE) para desarrollar estándares formales de gemelos digitales y evaluación Sim2Real.

Propuestas de estándares: - **ISO/IEC JTC 1/SC 41 - Internet of Things:** Estándar para arquitectura y interfaces de gemelos digitales - **IEEE P2806 - Digital Twin Framework:** Estándar para fidelidad, sincronización y validación de gemelos - **ISO/IEC TR 5469 - AI Functional Safety:** Estándar para validación de sistemas autónomos entrenados en simulación

Actividades: - Participar en working groups de estandarización - Proponer métricas y protocolos basados en investigación - Coordinar con industria para adopción de estándares

Impacto Esperado

Estandarización aceleraría progreso del campo en 2-3x mediante comparación objetiva, reduciría esfuerzo redundante y facilitaría meta-análisis cuantitativos. Adopción industrial se vería beneficiada por interoperabilidad y certificación basada en estándares.

4.9.3. 9.3. Simuladores Diferenciables para Optimización End-to-End

Motivación y Contexto

Simuladores tradicionales son “cajas negras”: no proveen gradientes de métricas de desempeño respecto a parámetros de simulación. Esto limita calibración a métodos libres de derivadas (Bayesian Optimization, búsqueda grid) que son lentos y requieren muchas evaluaciones.

Visión: Desarrollar simuladores que soporten diferenciación automática, permitiendo optimización basada en gradientes para calibración rápida, co-diseño de sistemas y aprendizaje de dinámicas.

Direcciones de Investigación Específicas

9.3.1. Simuladores de Física Diferenciables Escalables **Objetivo:** Desarrollar motores de física que calculen gradientes de estados futuros respecto a parámetros físicos (masa, fricción, rigidez) y comandos de control, escalando a sistemas complejos (100+ cuerpos rígidos, 1000+ contactos).

Enfoques técnicos: - **Diferenciación automática de motores existentes:** Reimplementar MuJoCo, PyBullet en frameworks diferenciables (JAX, PyTorch) - **Diferenciación implícita:** Para solucionadores de contacto (LCP, QP), usar teorema de la función implícita para calcular gradientes sin diferenciar solver - **Paralelización en GPU:** Aprovechar paralelismo masivo de GPUs para simular y calcular gradientes de miles de escenarios simultáneamente

Ejemplos de implementaciones: - **DiffTaichi:** Framework diferenciable para simulación de física (fluidos, cuerpos rígidos, deformables) - **Brax:** Motor de física diferenciable en JAX optimizado para RL - **Dojo:** Simulador diferenciable enfocado en contacto y manipulación

Métricas de éxito: - Gradientes exactos (error < 1e-6 vs diferencias finitas) - Escalabilidad: 100+ cuerpos rígidos a > 1000 FPS en GPU - Memoria: < 10 GB para escenas típicas

Desafíos: - Contacto es inherentemente no diferenciable (discontinuidades); requiere suavizado o diferenciación implícita - Costo de memoria de backpropagation a través de simulaciones largas

9.3.2. Calibración Automática Basada en Gradientes Objetivo: Utilizar simuladores diferenciables para calibrar parámetros físicos minimizando discrepancia con trayectorias reales mediante descenso de gradiente.

Formulación:

$$\min_{\theta} \mathcal{L}(\theta) = \sum_{i=1}^N \|\text{sim}(\theta, s_0^i, u^i) - \tau_{\text{real}}^i\|^2$$

Donde: - θ : Parámetros físicos a calibrar (masa, fricción, etc.) - $\text{sim}(\theta, s_0, u)$: Trayectoria simulada con parámetros θ , estado inicial s_0 , comandos u - τ_{real} : Trayectoria real observada - Gradientes $\nabla_{\theta}\mathcal{L}$ se calculan mediante backpropagation a través del simulador

Ventajas sobre métodos libres de derivadas: - **Velocidad:** Convergencia en 10-50 iteraciones vs 500-1000 de BO - **Escalabilidad:** Puede optimizar 100+ parámetros simultáneamente - **Precisión:** Encuentra mínimos locales más precisos

Métricas de éxito: - Calibración de 20 parámetros en < 1 hora (vs 2-3 días con BO) - Error de predicción < 5 % en trayectorias de validación

Desafíos: - Mínimos locales: gradientes pueden quedar atrapados en óptimos locales pobres - Sensibilidad a inicialización: requiere estimaciones iniciales razonables

9.3.3. Diseño Co-Optimizado de Sistemas Objetivo: Optimizar simultáneamente morfología de robot (ej. longitud de enlaces, distribución de masa) y política de control para maximizar desempeño en tarea.

Formulación:

$$\max_{\theta_{\text{morph}}, \theta_{\text{policy}}} \mathbb{E}[\text{reward}(\text{sim}(\theta_{\text{morph}}, \pi_{\theta_{\text{policy}}}))]$$

Donde: - θ_{morph} : Parámetros de morfología (geometría, masa) - θ_{policy} : Parámetros de política de control - Se optimiza conjuntamente mediante gradientes a través del simulador diferenciable

Aplicaciones: - Diseño de robots para tareas específicas (ej. locomoción en terreno irregular) - Co-diseño de sensores y algoritmos de percepción - Optimización de manipuladores para ensamblaje

Métricas de éxito: - Desempeño 20-50 % superior a diseño manual + optimización de política separada - Descubrimiento de morfologías no intuitivas pero efectivas

Desafíos: - Espacio de búsqueda combinatorio (morfología discreta + política continua) - Validación en hardware real de diseños optimizados

9.3.4. Identificación de Modelo con PINNs **Objetivo:** Usar Physics-Informed Neural Networks para aprender modelos de dinámica que respeten leyes físicas conocidas (conservación de energía, momentum) y se ajusten a datos observados.

Formulación:

$$\min_{\theta} \mathcal{L}_{\text{data}}(\theta) + \lambda \mathcal{L}_{\text{physics}}(\theta)$$

Donde: - $\mathcal{L}_{\text{data}}$: Error de predicción en datos observados - $\mathcal{L}_{\text{physics}}$: Violación de ecuaciones físicas (ej. $\frac{d}{dt}(m\dot{x}) = F$) - λ : Peso que balancea ajuste a datos y respeto a física

Ventajas: - **Eficiencia de datos:** Requiere menos datos que aprendizaje puramente data-driven - **Extrapolación:** Generaliza mejor fuera de régimen de entrenamiento gracias a restricciones físicas - **Interpretabilidad:** Parámetros aprendidos tienen significado físico

Métricas de éxito: - Predicción precisa con 10x menos datos que NN estándar - Extrapolación a regímenes no vistos con < 20 % error

Desafíos: - Balance entre $\mathcal{L}_{\text{data}}$ y $\mathcal{L}_{\text{physics}}$ (elección de λ) - Escalabilidad a sistemas de alta dimensión

Impacto Esperado

Simuladores diferenciables acelerarían calibración de gemelos digitales de días a horas (10-100x), habilitarían co-diseño de sistemas optimizados end-to-end y permitirían aprendizaje de dinámicas con menor cantidad de datos. Aplicaciones en robótica, vehículos autónomos y manufactura se beneficiarían significativamente.

4.9.4. 9.4. Integración de Modelos Fundacionales

Motivación y Contexto

Modelos fundacionales pre-entrenados en datos masivos (GPT-4, CLIP, SAM) capturan conocimiento general del mundo que puede facilitar transferencia sim-to-real mediante representaciones robustas y razonamiento de alto nivel.

Visión: Aprovechar modelos fundacionales para reducir el Sim2Real Gap mediante representaciones visuales robustas, generación de datos sintéticos realistas y políticas de control condicionadas en lenguaje natural.

Direcciones de Investigación Específicas

9.4.1. Vision-Language Models para Robótica **Objetivo:** Utilizar modelos como CLIP para aprender representaciones visuales que sean invariantes a diferencias de apariencia entre simulación y realidad.

Enfoques técnicos: - **Políticas condicionadas en CLIP embeddings:** En lugar de procesar imágenes crudas, políticas operan sobre embeddings de CLIP que son más robustos a cambios de dominio. - **Zero-shot transfer con instrucciones en lenguaje natural:** Políticas condicionadas en descripciones de tarea (“pick up the red cube”) pueden generalizar a nuevas tareas sin re-entrenamiento. - **Visual grounding:** Usar modelos como SAM (Segment Anything) para segmentación robusta de objetos en imágenes sim y real.

Ejemplos de trabajos: - **RT-1, RT-2 (Google):** Políticas de manipulación condicionadas en instrucciones de lenguaje natural - **CLIP-Fields:** Representaciones 3D de escenas usando embeddings de CLIP para navegación y manipulación

Métricas de éxito: - Reducción de gap perceptual en 30-50 % comparado con políticas basadas en imágenes crudas - Zero-shot transfer a 10+ nuevas tareas con > 60 % éxito

Desafíos: - Modelos fundacionales son grandes (> 1B parámetros); latencia de inferencia puede ser prohibitiva para control en tiempo real - Fine-tuning de modelos fundacionales en datos robóticos limitados sin degradar capacidades generales

9.4.2. Generación de Datos Sintéticos con Modelos Generativos **Objetivo:** Usar Diffusion Models y GANs avanzados para generar datos sintéticos fotorrealistas que reduzcan el gap de apariencia.

Enfoques técnicos: - **Text-to-Image para escenas robóticas:** Generar imágenes de escenas de manipulación desde descripciones textuales (“robot grasping a red mug on a cluttered table”) - **Image-to-Image translation:** Refinar imágenes sintéticas para mayor fotorrealismo usando modelos generativos entrenados en datos reales - **Data augmentation inteligente:** Usar modelos generativos para crear variaciones realistas (iluminación, occlusiones) de escenas sintéticas

Ejemplos de modelos: - **Stable Diffusion, DALL-E 3:** Generación text-to-image de alta calidad - **ControlNet:** Control fino de generación (pose de objetos, layout de escena) - **DreamFusion:** Generación de modelos 3D desde texto

Métricas de éxito: - Imágenes sintéticas indistinguibles de reales (FID score < 20) - Políticas entrenadas en datos generados logran $> 80\%$ de desempeño de políticas entrenadas en datos reales

Desafíos: - Consistencia temporal: generar secuencias de video coherentes, no solo imágenes aisladas - Control de generación: asegurar que objetos y poses generadas son físicamente plausibles

9.4.3. Aprendizaje Multi-Tarea con Modelos Fundacionales Objetivo: Pre-entrenar políticas en tareas diversas usando modelos fundacionales, luego adaptar rápidamente a nuevas tareas específicas mediante fine-tuning.

Enfoques técnicos: - **Pre-entrenamiento en datasets multi-tarea:** Entrenar políticas en millones de demostraciones de tareas diversas (ej. Open X-Embodiment dataset) - **Transfer Learning desde representaciones de modelos fundacionales:** Usar embeddings de CLIP, DINOv2 como features para políticas - **Prompt-based adaptation:** Adaptar políticas a nuevas tareas mediante prompts en lenguaje natural sin re-entrenamiento

Ejemplos de trabajos: - **RT-X (Google):** Política multi-tarea entrenada en 22 robots y 1M+ demos - **Octo:** Modelo fundacional open-source para manipulación robótica

Métricas de éxito: - Adaptación a nueva tarea con < 10 demos (vs 100-1000 sin pre-entrenamiento) - Generalización a 50+ tareas con desempeño promedio $> 70\%$

Desafíos: - Catastrophic forgetting: fine-tuning en nueva tarea puede degradar desempeño en tareas antiguas - Escalabilidad de entrenamiento: requiere infraestructura masiva (1000+ GPUs)

Impacto Esperado

Integración de modelos fundacionales reduciría el gap perceptual en 30-50 %, aceleraría aprendizaje de nuevas tareas en 10-100x y habilitaría políticas que generalizan a tareas no vistas mediante instrucciones en lenguaje natural. Robótica de propósito general se vería significativamente beneficiada.

4.9.5. 9.5. Validación Formal y Certificación

Motivación y Contexto

Para aplicaciones críticas de seguridad (conducción autónoma, aviación, robótica médica), validación informal mediante pruebas empíricas es insuficiente. Se requiere

validación formal con garantías matemáticas de seguridad y **certificación** por organismos reguladores.

Visión: Desarrollar métodos formales para verificar propiedades de seguridad de sistemas entrenados en simulación y frameworks de certificación aceptados por reguladores.

Direcciones de Investigación Específicas

9.5.1. Métodos Formales para Verificación **Objetivo:** Aplicar técnicas de verificación formal (model checking, síntesis de controladores) para probar propiedades de seguridad en gemelos digitales.

Enfoques técnicos: - **Model checking de gemelos digitales:** Verificar que el gemelo satisface propiedades de seguridad (ej. “nunca colisiona con obstáculos”) en todos los estados alcanzables. - **Síntesis de controladores con garantías:** Sintetizar controladores que proveen garantías formales de seguridad basándose en modelos del gemelo. - **Pruebas de equivalencia:** Probar que gemelo y sistema físico son bisimilares bajo ciertas abstracciones.

Herramientas: - **UPPAAL, SPIN:** Model checkers para sistemas de tiempo real - **TuLiP:** Síntesis de controladores desde especificaciones temporales (LTL, GR(1)) - **KeYmaera X:** Verificación de sistemas ciberfísicos usando lógica dinámica diferencial

Métricas de éxito: - Verificación de propiedades de seguridad en gemelos de 10+ estados en < 1 hora - Síntesis de controladores certificados que garantizan seguridad en 95 % de escenarios

Desafíos: - Escalabilidad: verificación formal sufre de explosión de estados en sistemas complejos - Abstracción: requiere abstracción cuidadosa del gemelo que preserve propiedades de interés

9.5.2. Cuantificación Rigurosa de Incertidumbre **Objetivo:** Desarrollar métodos para cuantificar incertidumbre en predicciones de gemelos y propagar incertidumbre a través de simulaciones para análisis de riesgo.

Enfoques técnicos: - **Intervalos de confianza calibrados:** Asegurar que intervalos de confianza del gemelo tienen cobertura empírica correcta (ej. 95 % de observaciones reales caen en intervalo de 95 %). - **Propagación de incertidumbre:** Usar métodos de Monte Carlo, Unscented Transform o redes neuronales probabilísticas para propagar incertidumbre de parámetros a predicciones. - **Worst-case analysis:** Identificar configuraciones de parámetros dentro de región de incertidumbre que maximizan riesgo (ej. probabilidad de colisión).

Métricas de éxito: - Calibración de incertidumbre: error de calibración esperado (ECE) < 0.05 - Worst-case analysis identifica escenarios críticos con > 90 %

precisión

Desafíos: - Cuantificación de incertidumbre epistémica (falta de conocimiento) vs aleatoriedad (estocasticidad inherente) - Costo computacional de propagación de incertidumbre en simulaciones largas

9.5.3. Frameworks de Certificación **Objetivo:** Desarrollar frameworks de certificación para gemelos digitales y sistemas entrenados en simulación, aceptados por organismos reguladores (FAA, NHTSA, FDA).

Componentes de framework: - **Estándares de fidelidad:** Definir niveles de fidelidad requeridos para diferentes aplicaciones (ej. Level 1-5 similar a SAE autonomy levels) - **Protocolos de validación:** Establecer procedimientos estandarizados para validar gemelos contra sistemas reales - **Auditoría y trazabilidad:** Documentar proceso de desarrollo, calibración y validación para auditoría - **Certificación continua:** Monitoreo continuo de drift y re-certificación cuando sea necesario

Estándares relevantes: - **ISO 26262:** Seguridad funcional en vehículos - **DO-178C:** Software en sistemas aviónicos - **IEC 62304:** Software de dispositivos médicos

Métricas de éxito: - Adopción de framework por al menos 1 organismo regulador en 5 años - Certificación de 10+ sistemas basados en gemelos digitales

Desafíos: - Conservadurismo de reguladores: resistencia a aprobar métodos basados en simulación - Responsabilidad legal: quién es responsable cuando un gemelo falla

Impacto Esperado

Validación formal y certificación habilitarían despliegue de sistemas entrenados en simulación en aplicaciones críticas de seguridad, con aceptación regulatoria. Reducción de costos de certificación (50-80% vs pruebas puramente físicas) aceleraría innovación en vehículos autónomos, aviación y medicina.

4.9.6. 9.6. Escalabilidad a Sistemas Multi-Agente

Motivación y Contexto

Muchas aplicaciones reales involucran múltiples agentes interactuando (flotas de vehículos autónomos, robots colaborativos en manufactura, drones en enjambre). Escalabilidad del Sim2Real Gap a estos contextos es poco explorada.

Visión: Extender técnicas Sim2Real a sistemas multi-agente complejos, habilitando coordinación, comunicación y comportamientos emergentes robustos.

Direcciones de Investigación Específicas

9.6.1. Sim2Real para Coordinación Multi-Agente **Objetivo:** Desarrollar técnicas de DR, DA y calibración para políticas de coordinación multi-agente que transfieran a sistemas reales.

Enfoques técnicos: - **Domain Randomization de interacciones:** Aleatorizar retardos de comunicación, pérdida de paquetes, errores de localización relativa
 - **Curriculum Learning de complejidad:** Comenzar con 2 agentes, incrementar progresivamente a 10+
- Validación escalonada: Simulación → HIL con agentes reales + virtuales → despliegue completo

Aplicaciones: - Flotas de vehículos autónomos (platooning, intersecciones) - Robots colaborativos en almacenes (coordinación de pick-and-place) - Drones en enjambre (búsqueda y rescate, mapeo)

Métricas de éxito: - Transferencia exitosa de políticas de coordinación para 5+ agentes - Robustez a fallos de agentes individuales (degradación < 20 % con 1 agente fallido)

Desafíos: - Explosión combinatoria de estados con número de agentes - Comportamientos emergentes en simulación que no se replican en realidad

9.6.2. Gemelos Digitales de Sistemas de Sistemas **Objetivo:** Desarrollar arquitecturas de gemelos digitales jerárquicos para sistemas complejos con múltiples subsistemas interactuando.

Enfoques técnicos: - **Modelado jerárquico:** Gemelos de componentes individuales + gemelo de sistema completo - **Sincronización distribuida:** Protocolos para mantener consistencia entre gemelos de subsistemas - **Gestión de latencia:** Compensar retardos de comunicación entre gemelos distribuidos

Aplicaciones: - Smart cities (tráfico + energía + agua) - Fábricas inteligentes (múltiples líneas de producción + logística) - Sistemas de transporte (vehículos + infraestructura + control de tráfico)

Métricas de éxito: - Fidelidad de sistema completo > 0.85 con gemelos de 10+ subsistemas - Latencia de sincronización < 100 ms

Desafíos: - Escalabilidad computacional: simulación de sistemas masivos en tiempo real - Interoperabilidad: gemelos desarrollados por diferentes organizaciones deben integrarse

9.6.3. Aprendizaje Federado para Gemelos Distribuidos **Objetivo:** Entrenar modelos compartidos desde múltiples gemelos digitales sin centralizar datos, preservando privacidad y propiedad intelectual.

Enfoques técnicos: - **Federated Learning:** Entrenar modelo global mediante agregación de actualizaciones de modelos locales entrenados en cada gemelo - **Adaptación local + agregación global:** Cada gemelo se adapta a su sistema

físico específico, luego se agrega conocimiento común - **Privacidad diferencial:** Añadir ruido a actualizaciones locales para preservar privacidad

Aplicaciones: - Flotas de vehículos de múltiples fabricantes compartiendo conocimiento - Fábricas de múltiples organizaciones mejorando diagnóstico de fallos colaborativamente - Hospitales compartiendo modelos de gemelos de pacientes sin compartir datos sensibles

Métricas de éxito: - Modelo global logra 90 % de desempeño de modelo centralizado - Garantías de privacidad: epsilon-differential privacy con $\epsilon < 1$

Desafíos: - Heterogeneidad de datos: gemelos de diferentes organizaciones pueden tener distribuciones muy diferentes - Comunicación: ancho de banda limitado para transmitir actualizaciones de modelos grandes

Impacto Esperado

Extensión de técnicas Sim2Real a sistemas multi-agente habilitaría aplicaciones de gran escala (smart cities, flotas autónomas, manufactura distribuida) con coordinación robusta y comportamientos emergentes confiables. Aprendizaje federado permitiría colaboración sin comprometer privacidad o propiedad intelectual.

4.9.7. 9.7. Explicabilidad e Interpretabilidad

Motivación y Contexto

La falta de interpretabilidad de por qué una transferencia sim-to-real falla o tiene éxito dificulta debugging y mejora iterativa. Sistemas “caja negra” son difíciles de certificar y generar desconfianza en usuarios finales.

Visión: Desarrollar métodos de explicabilidad que identifiquen causas raíz de fallos de transferencia y proporcionen insights accionables para mejora.

Direcciones de Investigación Específicas

9.7.1. Diagnóstico Automático de Fallos de Transferencia **Objetivo:** Desarrollar algoritmos que identifiquen automáticamente qué aspectos del Sim2Real Gap causan degradación de desempeño.

Enfoques técnicos: - **Análisis de sensibilidad:** Variar parámetros de simulación sistemáticamente y medir impacto en desempeño de transferencia para identificar parámetros críticos - **Análisis de ablación automatizado:** Entrenar múltiples variantes de políticas con diferentes componentes de DR/DA deshabilitados para identificar componentes críticos - **Visualización de discrepancias:** Generar visualizaciones de diferencias entre distribuciones simulada y real (ej. t-SNE de features)

Métricas de éxito: - Identificación correcta de causa raíz en 80 % de casos de fallo - Tiempo de diagnóstico < 1 hora (vs días de debugging manual)

Desafíos: - Múltiples causas interactuantes: gap puede ser multi-facético con causas confundidas - Generalización: método debe funcionar en diferentes dominios y tipos de gap

9.7.2. Explicaciones Contrafactualas **Objetivo:** Responder preguntas del tipo “¿Qué cambios en simulación harían que la transferencia tenga éxito?”

Enfoques técnicos: - **Generación de contrafactualas:** Identificar cambios mínimos en parámetros de simulación que harían que la política tenga éxito en realidad - **Análisis de sensibilidad inverso:** Dado un fallo en realidad, inferir qué parámetros de simulación fueron mal calibrados - **Visualización de ejemplos sintéticos:** Generar ejemplos sintéticos que revelan vulnerabilidades de políticas (ej. adversarial examples)

Métricas de éxito: - Contrafactualas identifican cambios que mejoran éxito en 70 % de casos - Cambios sugeridos son accionables (pueden implementarse en < 1 semana)

Desafíos: - Espacio de búsqueda de contrafactualas es exponencial - Contrafactualas pueden ser no únicas (múltiples cambios posibles)

9.7.3. Interpretabilidad de Modelos de Adaptación **Objetivo:** Comprender qué aprenden redes de Domain Adaptation (DANN, GANs) y qué features son invariantes al dominio.

Enfoques técnicos: - **Visualización de features:** Usar técnicas como Grad-CAM, SHAP para visualizar qué regiones de imágenes son importantes para clasificación - **Ánalisis de representaciones:** Proyectar features aprendidas por DANN en 2D/3D para visualizar separación de dominios - **Pruebas de concepto:** Entrenar clasificadores lineales sobre features de DANN para verificar que son invariantes al dominio

Métricas de éxito: - Identificación de 5-10 features clave que son invariantes al dominio - Visualizaciones comprensibles para no expertos

Desafíos: - Interpretabilidad de redes profundas es problema abierto - Features aprendidas pueden ser distribuidas (no localizadas en neuronas individuales)

Impacto Esperado

Explicabilidad aceleraría ciclos de desarrollo en 2-5x mediante identificación rápida de causas raíz de fallos y guía para mejoras. Certificación y adopción industrial se beneficiarían de mayor transparencia y confianza en sistemas basados en simulación.

4.9.8. 9.8. Aplicaciones Emergentes

Direcciones de Investigación Específicas

9.8.1. Robótica Médica y Quirúrgica **Oportunidades:** - Gemelos digitales de pacientes para planificación quirúrgica personalizada - Transferencia sim-to-real de políticas de manipulación de tejidos blandos - Validación de dispositivos médicos en gemelos antes de ensayos clínicos

Desafíos únicos: - Variabilidad anatómica entre pacientes (cada paciente es un dominio diferente) - Regulación estricta (FDA): requiere validación formal y certificación - Ética: fallos pueden tener consecuencias graves para pacientes

Impacto potencial: Reducción de riesgos en cirugía, personalización de tratamientos, aceleración de desarrollo de dispositivos médicos (50 % reducción en tiempo de aprobación).

9.8.2. Agricultura de Precisión **Oportunidades:** - Gemelos digitales de cultivos para optimización de riego y fertilización - Transferencia de políticas de navegación y manipulación en entornos agrícolas - Sim2Real para robots de cosecha y monitoreo

Desafíos únicos: - Variabilidad ambiental extrema (clima, suelo, plagas) - Objetos deformables y no rígidos (frutas, plantas) - Entornos no estructurados (campos abiertos vs fábricas controladas)

Impacto potencial: Aumento de productividad agrícola (20-30 %), reducción de uso de agua y fertilizantes (30-50 %), sostenibilidad ambiental.

9.8.3. Construcción y Mantenimiento de Infraestructura **Oportunidades:**

- Gemelos digitales de edificios y puentes para inspección predictiva - Transferencia de políticas de robots de construcción y reparación - Validación de planes de construcción en simulación antes de ejecución

Desafíos únicos: - Escalabilidad: infraestructura es masiva (edificios de 100+ pisos, puentes de km) - Ciclo de vida largo (50-100 años): gemelos deben mantenerse por décadas - Integración con BIM (Building Information Modeling) y CAD existente

Impacto potencial: Reducción de costos de construcción (15-25 %), mejora de seguridad (50 % reducción de accidentes), extensión de vida útil de infraestructura (20-30 %).

9.8.4. Exploración Espacial **Oportunidades:** - Gemelos digitales de rovers y satélites para operación remota - Transferencia de políticas a entornos extraterrestres (Luna, Marte) - Validación de misiones en simulación de alta fidelidad

Desafíos únicos: - Entornos extremos (radiación, vacío, temperaturas extremas) - Latencia de comunicación (minutos a horas para Marte) - Imposibilidad de pruebas reales en Tierra (gravedad, atmósfera diferentes)

Impacto potencial: Reducción de riesgos de misión, aumento de autonomía de rovers (operación sin intervención humana por días), aceleración de exploración.

Impacto Esperado de Aplicaciones Emergentes

Extensión de técnicas Sim2Real a nuevos dominios (medicina, agricultura, construcción, espacio) multiplicaría el impacto social y económico en 10-100x. Cada dominio presenta desafíos únicos que impulsarían desarrollo de nuevas técnicas, beneficiando también aplicaciones tradicionales.

4.9.9. 9.9. Democratización mediante Herramientas y Ecosistemas

Motivación y Contexto

Técnicas avanzadas (Meta-Learning, simuladores diferenciables, gemelos de alta fidelidad) tienen adopción industrial limitada por complejidad, falta de herramientas maduras y requisitos de expertise alto.

Visión: Democratizar acceso a técnicas Sim2Real avanzadas mediante desarrollo de herramientas open-source, plataformas cloud y ecosistemas integrados.

Direcciones de Investigación Específicas

9.9.1. Frameworks Integrados Sim2Real **Objetivo:** Desarrollar plataformas que integren simuladores, técnicas de DR/DA/TL y pipelines de validación con APIs unificadas.

Componentes requeridos: - **Interfaz unificada para múltiples simuladores:** Abstraer diferencias entre Gazebo, MuJoCo, Isaac Sim, PyBullet - **Librerías de DR/DA/TL:** Implementaciones de referencia de técnicas estado del arte - **Pipelines de validación:** Protocolos automatizados para evaluar transferencia sim-to-real - **Ejemplos y tutoriales:** Casos de uso documentados para diferentes dominios

Ejemplos de iniciativas: - **AutoDRIVE:** Ecosistema para conducción autónoma con simulador + hardware - **EAGERx:** Framework modular para robótica con soporte para sim-to-real - **Isaac Lab (NVIDIA):** Plataforma para RL en robótica con DR integrado

Métricas de éxito: - Adopción por 100+ grupos de investigación en 3 años - Reducción de tiempo de setup de proyectos Sim2Real de semanas a días - 1000+ stars en GitHub, 100+ contributors

Desafíos: - Mantenimiento sostenible: frameworks open-source requieren comunidad activa - Interoperabilidad: integrar herramientas de múltiples organizaciones

9.9.2. Gemelos Digitales como Servicio (DTaaS) **Objetivo:** Desarrollar plataformas cloud para creación, calibración y ejecución de gemelos digitales sin inversión en infraestructura local.

Servicios ofrecidos: - **Modelado asistido:** Herramientas de modelado con IA que generan gemelos desde CAD o video - **Auto-calibración:** Algoritmos que calibran gemelos automáticamente desde datos reales - **Simulación escalable:** Ejecución paralela de miles de simulaciones en cloud (GPU, TPU) - **Marketplace de modelos:** Gemelos pre-construidos para componentes comunes (motores, sensores, actuadores)

Ejemplos de plataformas: - **NVIDIA Omniverse:** Plataforma para colaboración y simulación de gemelos digitales - **Azure Digital Twins:** Servicio cloud de Microsoft para IoT y gemelos digitales - **AWS IoT TwinMaker:** Servicio de Amazon para construcción de gemelos operacionales

Modelo de negocio: - Freemium: uso básico gratuito, features avanzadas de pago - Pay-per-use: cobrar por horas de simulación, calibración, almacenamiento

Métricas de éxito: - 1000+ usuarios activos en primer año - Reducción de costo de desarrollo de gemelos en 50-80 % - 50+ gemelos publicados en marketplace

Desafíos: - Seguridad y privacidad: proteger propiedad intelectual de usuarios - Latencia: simulación en cloud puede tener latencia mayor que local

9.9.3. Librerías de Domain Randomization **Objetivo:** Desarrollar librerías open-source con implementaciones de DR adaptativa, BO para DR y distribuciones pre-configuradas.

Componentes: - **Implementaciones de referencia:** ADR, DR con BO, Curriculum DR - **Distribuciones pre-configuradas:** Para dominios comunes (conducción, manipulación, manufactura) - **Herramientas de visualización:** Visualizar distribuciones de parámetros, coverage de espacio de parámetros - **Análisis de sensibilidad:** Identificar parámetros críticos para aleatorización

Ejemplos de librerías: - **Domain Randomization Toolkit (DRT):** Librería en desarrollo para PyBullet y MuJoCo - **Isaac Gym:** Incluye soporte nativo para DR en entornos de RL

Métricas de éxito: - 500+ descargas en primer mes - Reducción de tiempo de implementación de DR de semanas a días - 50+ papers citando la librería en 2 años

Desafíos: - Generalidad vs especificidad: balance entre librería general y optimizada para dominios específicos

Impacto Esperado de Democratización

Herramientas y ecosistemas accesibles reducirían barrera de entrada en 10x, acelerando adopción industrial y académica. PYMEs y startups podrían aprovechar técnicas avanzadas sin inversión prohibitiva, democratizando innovación en robótica y autonomía.

4.9.10. 9.10. Consideraciones Éticas y Sociales

Motivación y Contexto

El despliegue de sistemas autónomos entrenados en simulación tiene implicaciones éticas y sociales que deben abordarse proactivamente para asegurar desarrollo responsable.

Direcciones de Investigación Específicas

9.10.1. Sesgo en Simuladores y Datos Sintéticos

Objetivo: Auditar y mitigar sesgos en simuladores que pueden propagarse a sistemas reales.

Enfoques técnicos: - **Auditoría de representación:** Verificar que simuladores representan diversidad de demografías, escenarios y condiciones - **Mitigación de sesgo:** Técnicas de re-balanceo de datos sintéticos, re-ponderación de pérdidas - **Validación de equidad:** Medir desempeño de sistemas transferidos en subgrupos demográficos

Ejemplos de sesgos: - Simuladores de conducción que sub-representan peatones de ciertas demografías - Simuladores de manipulación que solo incluyen objetos de ciertos tipos (occidentales)

Métricas de éxito: - Paridad de desempeño entre subgrupos (diferencia < 5 %) - Representación proporcional de demografías en datos sintéticos

Desafíos: - Definir qué constituye “equidad” en contextos específicos - Trade-off entre equidad y desempeño promedio

9.10.2. Transparencia y Accountability

Objetivo: Establecer trazabilidad de decisiones: qué datos (sintéticos vs reales) informaron qué decisiones.

Enfoques técnicos: - **Logging exhaustivo:** Registrar todos los datos, modelos y decisiones durante desarrollo - **Explicaciones para stakeholders no técnicos:** Generar explicaciones comprensibles de por qué un sistema tomó cierta decisión - **Auditoría post-incidente:** Capacidad de reconstruir estado del sistema y datos usados en caso de fallo

Marcos legales relevantes: - **GDPR (Europa):** Derecho a explicación de decisiones automatizadas - **AI Act (Europa):** Requisitos de transparencia para sistemas de IA de alto riesgo

Métricas de éxito: - Trazabilidad completa de decisiones en 100 % de casos - Explicaciones comprensibles para 80 % de stakeholders no técnicos

Desafíos: - Balance entre transparencia y protección de propiedad intelectual - Costo de logging y almacenamiento de datos exhaustivos

9.10.3. Impacto Laboral y Social

Objetivo: Estudiar impacto de automatización habilitada por Sim2Real en empleo y diseñar transiciones justas.

Enfoques: - **Estudios de impacto:** Investigación empírica de efectos de automatización en sectores específicos (manufactura, logística, transporte) - **Diseño de transiciones:** Programas de re-capacitación y upskilling para trabajadores afectados - **Distribución de beneficios:** Políticas para asegurar que beneficios de automatización se distribuyan equitativamente

Ejemplos de impactos: - Conducción autónoma: 3.5M conductores profesionales en USA potencialmente afectados - Manufactura: Automatización puede desplazar trabajos rutinarios pero crear nuevos roles técnicos

Métricas de éxito: - Re-empleo de 70 % de trabajadores afectados en 2 años - Satisfacción laboral de trabajadores re-capacitados > 70 %

Desafíos: - Predicción de impactos a largo plazo es incierta - Coordinación entre gobierno, industria y academia

Impacto Esperado de Consideraciones Éticas

Abordar proactivamente consideraciones éticas aseguraría desarrollo responsable de tecnologías Sim2Real, maximizando beneficios sociales y minimizando daños. Confianza pública y aceptación regulatoria se verían beneficiadas, acelerando adopción sostenible.

4.9.11. 9.11. Síntesis de Trabajos Futuros

Las direcciones de investigación futura propuestas abarcan desde aspectos técnicos fundamentales (gemelos adaptativos, simuladores diferenciables) hasta consideraciones prácticas (democratización, estandarización) y éticas (sesgo, transparencia, impacto social). La siguiente tabla sintetiza prioridades según impacto esperado y viabilidad:

Tabla 9.1: Priorización de Direcciones de Investigación Futura

Dirección	Impacto Esperado	Viabilidad (5 años)	Prioridad
Gemelos Digitales Adaptativos	Muy Alto	Alta	Crítica
Métricas/Benchmarks	Alto	Alta	Crítica
Muy Alto	Media-Alta	Alta	Alta
Modelos Fundacionales	Muy Alto	Media	Alta
Alto	Media-Baja	Media	Media
Escalabilidad Multi-Agente	Media	Media	Media
Explicabilidad e Interpretabilidad	Media	Alta	Media
Emergentes	Muy Alto	Variable	Media-Alta
Consideraciones Éticas y Sociales	Alto	Alta	Alta

Recomendaciones para la comunidad:

1. **Priorizar inversión** en gemelos adaptativos y estandarización (impacto alto, viabilidad alta)

2. **Fomentar colaboración** entre academia, industria y gobierno para democratización y estandarización
3. **Abordar ética proactivamente** para asegurar desarrollo responsable y aceptación social
4. **Explorar aplicaciones emergentes** para multiplicar impacto social y económico
5. **Mantener balance** entre investigación fundamental (simuladores diferenciales, validación formal) y aplicada (herramientas, casos de uso)

El futuro del campo Sim2Real reside en la convergencia de estas direcciones: gemelos adaptativos que co-evolucionan con sistemas físicos, validados formalmente, accesibles mediante plataformas democratizadas, aplicados a dominios emergentes de alto impacto, y desarrollados con consideración ética y social. La comunidad debe trabajar colaborativamente para realizar esta visión en los próximos 5-10 años.

Referencias

- [1] Ilge Akkaya et al. Solving rubik's cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- [2] Jean Pierre Allamaa et al. Learning based nmpc adaptation for autonomous driving using parallelized digital twin. *IEEE Transactions on Intelligent Vehicles*, 2024.
- [3] Dario Amodei et al. Concrete problems in ai safety. *arXiv preprint arXiv:1606.06565*, 2016.
- [4] Rika Antonova et al. Learning physics models from visual observations using deep neural networks. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 5565–5572, 2017.
- [5] Konstantinos Bousmalis et al. Using simulation and domain adaptation to improve efficiency of deep robotic grasping. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 4243–4250, 2018.
- [6] Roberto Calandra et al. Bayesian optimization for learning gaits under uncertainty. *Annals of Mathematics and Artificial Intelligence*, 76(1):5–23, 2016.

- [7] Jiahong Chen et al. Closing the simulation-to-reality gap for digital twin-assisted fault diagnosis: Sim2real knowledge transfer with contrastive learning. *IEEE/ASME Transactions on Mechatronics*, 2024.
- [8] Jack Collins et al. A review of physics simulators for robotic applications. *IEEE Access*, 9:51416–51431, 2021.
- [9] Nicolas Courty et al. Optimal transport for domain adaptation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(9):1853–1865, 2017.
- [10] Filipe de Avila Belbute-Peres et al. End-to-end differentiable physics for learning and control. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, pages 7178–7189, 2018.
- [11] Alexey Dosovitskiy et al. Carla: An open urban driving simulator. In *Conference on Robot Learning (CoRL)*, pages 1–16, 2017.
- [12] Chelsea Finn et al. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning (ICML)*, pages 1126–1135, 2017.
- [13] Yaroslav Ganin and Victor Lempitsky. Unsupervised domain adaptation by backpropagation. In *International Conference on Machine Learning (ICML)*, pages 1180–1189, 2015.
- [14] Michael Grieves and John Vickers. Digital twin: Mitigating unpredictable, undesirable emergent behavior in complex systems. In *Transdisciplinary Perspectives on Complex Systems*, pages 85–113. Springer, 2017.
- [15] Eric Heiden et al. Neuralsim: Augmenting differentiable simulators with neural networks. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 9474–9481, 2021.
- [16] Xue Min Hu, Shen Li, Ting Huang, et al. How simulation helps autonomous driving: A survey of sim2real, digital twins, and parallel intelligence. *arXiv preprint arXiv:2305.01263*, 2023.
- [17] Stephen James et al. Sim-to-real via sim-to-sim: Data-efficient robotic grasping via randomized-to-canonical adaptation networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 12627–12637, 2019.
- [18] Abhishek Kadian et al. Sim2real predictivity: Does evaluation in simulation predict real-world performance? *IEEE Robotics and Automation Letters*, 5(4):6670–6677, 2020.

- [19] Sunny Katyara, Sanjiv Sharma, Praveen Damacharla, et al. Benchmarking sim2real gap: High-fidelity digital twinning of agile manufacturing. *arXiv preprint arXiv:2409.10784*, 2024.
- [20] Philip Koopman and Michael Wagner. Autonomous vehicle safety: An interdisciplinary challenge. *IEEE Intelligent Transportation Systems Magazine*, 9(1):90–96, 2017.
- [21] Werner Kritzinger et al. Digital twin in manufacturing: A categorical literature review and classification. *IFAC-PapersOnLine*, 51(11):1016–1022, 2018.
- [22] David Liu et al. Digital twin (dt)-cyclegan: Enabling zero-shot sim-to-real transfer of visual grasping models. *IEEE Robotics and Automation Letters*, 8(5):2876–2883, 2023.
- [23] M^a Mercedes Lopez Torné, Anthony Simeonov, Zechu Li, et al. Reconciling reality through simulation: A real-to-sim-to-real approach for robust manipulation. *arXiv preprint arXiv:2403.03949*, 2024.
- [24] Jeffrey Mahler et al. Dex-net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics. In *Robotics: Science and Systems (RSS)*, 2017.
- [25] Bhairav Mehta et al. Active domain randomization. In *Conference on Robot Learning (CoRL)*, pages 1162–1176, 2020.
- [26] Fabio Muratore et al. Data-efficient domain randomization with bayesian optimization. *IEEE Robotics and Automation Letters*, 6(2):911–918, 2021.
- [27] Fabio Muratore et al. Robot learning from randomized simulations: A review. *Frontiers in Robotics and AI*, 9:799893, 2022.
- [28] OpenAI. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 39(1):3–20, 2019.
- [29] OpenAI et al. Solving rubik’s cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- [30] Su-Young Park et al. Enhancement of control performance for degraded robot manipulators using digital twin and proximal policy optimization. *IEEE Robotics and Automation Letters*, 9(4):3456–3463, 2024.
- [31] Xue Bin Peng et al. Sim-to-real transfer of robotic control with dynamics randomization. In *IEEE International Conference on Robotics and Automation (ICRA)*, pages 3803–3810, 2018.

- [32] Lerrel Pinto et al. Robust adversarial reinforcement learning. In *International Conference on Machine Learning (ICML)*, pages 2817–2826, 2017.
- [33] Maziar Raissi et al. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [34] Fabio Ramos et al. Bayesian optimization for sim-to-real transfer. *arXiv preprint arXiv:1903.07408*, 2019.
- [35] Erica Salvato et al. Crossing the reality gap: A survey on sim-to-real transferability of robot controllers in reinforcement learning. *IEEE Access*, 9:153171–153187, 2021.
- [36] Chinmay Vilas Samak et al. Mixed-reality digital twins: Leveraging the physical and virtual worlds for hybrid sim2real transition of multi-agent reinforcement learning policies. *arXiv preprint*, 2024.
- [37] Rainer Stark et al. Development and operation of digital twins for technical systems and services. *CIRP Annals*, 68(1):129–132, 2019.
- [38] Fei Tao et al. Digital twin-driven product design, manufacturing and service with big data. *The International Journal of Advanced Manufacturing Technology*, 94(9):3563–3576, 2018.
- [39] Fei Tao et al. Digital twin in industry: State-of-the-art. *IEEE Transactions on Industrial Informatics*, 15(4):2405–2415, 2019.
- [40] Josh Tobin et al. Domain randomization for transferring deep neural networks from simulation to the real world. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 23–30, 2017.
- [41] Eric Tzeng et al. Deep domain confusion: Maximizing for domain invariance. *arXiv preprint arXiv:1412.3474*, 2014.
- [42] Jonathan Uesato et al. Rigorous agent evaluation: An adversarial approach to uncover catastrophic failures. *arXiv preprint arXiv:1812.01647*, 2018.
- [43] Kevin L Voogd, Jean Pierre Allamaa, Javier Alonso-Mora, et al. Reinforcement learning from simulation to real world autonomous driving using digital twin. *IFAC Advances in Control and Optimization of Dynamical Systems*, 56(2):1–6, 2023.

- [44] Yuanhong Zeng et al. Triple regression for camera agnostic sim2real robot grasping and manipulation tasks. In *IEEE Conference on Robotics and Automation*, 2023.
- [45] Wenshuai Zhao et al. Sim-to-real transfer in deep reinforcement learning for robotics: A survey. In *IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 737–744, 2020.